编程作业二： 语言模型

编程作业题：搭建基于解码器的语言模型

作业目标：实现一个基于解码器的语言模型（类似 GPT 结构），模型参数量约 300M，在小型文本数据集上做预训练（下词预测）。

1 实现因果多头自注意力模块

要求：不能直接调用 mutliheadAttention 模块。采用手写多头、注意力计算。实现因果掩码，softmax，输出注意力结果。

2. 实现线性归一化模块

要求：参照 GPT。

3. 实现完整的解码器语言模型

要求：包含词元嵌入层，选择一种位置编码，输出从 d 维向量映射到词表大小。计算下词的注意力得分。

4. 自己设计一个统计模型参数的函数。数据集自选。输入可以使用 BPE 分词。训练过程使得损失下降即可。不需要完整开始收敛。

提交要求：

提交完整的 python 源代码，标注注释。

提交一份实验报告，包含：模型超参表、参数量结果、训练损失截图。程序调试过程描述。一组字符串生成样例。

注意：在小模型（例如：n=4）上调试代码，300M 只做参数统计 + 推理演示。禁止直接粘贴 GPT 实现源代码。包括各组之间。